

Análisis profundo y preparación de datos para la predicción de la duración de la estancia hospitalaria (LOS): informe de proyecto

Thomas GIRAULT
Ingeniería de Sistemas
thoma19girault@gmail.com

Resumen

Este informe presenta la primera fase de un proyecto académico dedicado al análisis y predicción de la duración de la estancia hospitalaria (Length of Stay, LOS). El objetivo principal de esta etapa es preparar un conjunto de datos filtrado, explorar metódicamente su estructura estadística e identificar las características esenciales que pueden influir en la duración de la hospitalización. El trabajo realizado incluye una exploración descriptiva profunda, la detección e interpretación de valores atípicos (outliers), así como la evaluación de las relaciones entre variables clínicas y administrativas.

Se prestó especial atención a la reproducibilidad del análisis, la calidad de la limpieza de datos y la interpretación clínica de los resultados obtenidos. Los primeros análisis destacan una distribución del LOS centrada en torno a cuatro días, una asociación clara entre el número de readmisiones y la duración de la hospitalización, así como la presencia de marcadores biológicos, notablemente **bloodureanitro**, que presentan valores extremos clínicamente relevantes. Estos hallazgos sientan las bases necesarias para el diseño de un futuro modelo supervisado robusto y adaptado a la realidad de los datos hospitalarios.

Palabras clave: duración de estancia, LOS, exploración de datos, outliers, ACP, clustering.

1. Introducción

La gestión hospitalaria moderna depende críticamente de la capacidad de anticipar la duración de la ocupación de camas para optimizar recursos, reducir tiempos de espera y mejorar la calidad de la atención. La duración de la estancia hospitalaria (*Length of Stay*, LOS) constituye un indicador central, utilizado tanto para la planificación operativa como para la evaluación de la carga de trabajo clínica y el análisis del rendimiento de las instituciones de salud [2].

Varios estudios muestran que las comorbilidades médicas tienen un impacto significativo en el LOS. En particular, la comorbilidad médica en pacientes hospitalizados se ha asociado con un aumento promedio en la duración de la estancia y debería ser un eje de intervención prioritario [3].

En el marco del curso "Fundamentos de Ciencia de Datos", este proyecto busca analizar y preparar un conjunto de datos hospitalarios para constituir una base limpia, coherente y explotable en una fase posterior de modelado supervisado. El objetivo general es doble: por un lado, comprender en

profundidad la estructura estadística de los datos y, por otro, preparar técnicamente los datos para los algoritmos de aprendizaje automático.

El análisis exploratorio ocupa un lugar esencial en este proceso. Antes de cualquier intento de construcción de un modelo, es indispensable realizar un examen minucioso que permita identificar las relaciones pertinentes, los posibles sesgos, las incoherencias y los valores atípicos susceptibles de afectar a los algoritmos de aprendizaje automático. Esta fase de *data profiling* es particularmente crítica en los contextos biomédicos, donde los extremos pueden representar situaciones clínicas importantes en lugar de simples errores de medición.

El conjunto de datos estudiado proviene de la plataforma Kaggle [1], y contiene información clínica y administrativa como el IMC (`bmi`), la creatinina (`creatinine`), el nitrógeno ureico en sangre (`bloodureanitro`), el número de readmisiones (`rcount`), así como marcadores derivados de diagnósticos ICD-9. Estos datos, que combinan medidas biométricas, historial médico y variables hospitalarias, constituyen un soporte pertinente para la implementación de herramientas de predicción del LOS.

Desde un punto de vista operativo, la predicción de la duración de la estancia ofrece a los establecimientos hospitalarios una ventaja estratégica considerable: asignación dinámica de camas, distribución óptima del personal, mejor anticipación de las admisiones y reducción de ineficiencias estructurales. El análisis realizado en este proyecto se inscribe, por lo tanto, en una perspectiva de mejora de los procesos hospitalarios, al tiempo que desarrolla una metodología rigurosa de exploración de datos adaptada al ámbito de la salud.

En resumen, este estudio persigue tres objetivos principales: (1) comprender la estructura global y las particularidades del conjunto de datos, (2) detectar e interpretar los valores extremos desde un punto de vista estadístico y clínico, y (3) preparar una base de datos estable y limpia con miras a la fase de modelado predictivo. El conjunto de opciones metodológicas adoptadas tiene como objetivo garantizar la calidad de los datos y la robustez de los futuros análisis, de conformidad con las recomendaciones académicas y técnicas en ciencia de datos.

2. Metodología

La metodología aplicada en este proyecto se articula en varias etapas sucesivas, desde la importación de los datos hasta la creación de un conjunto de datos filtrado y limpio, pasando por una selección rigurosa de las variables pertinentes para el análisis.

2.1. Fuente y características del conjunto de datos

El conjunto de datos utilizado proviene de la plataforma Kaggle [1] y contiene inicialmente 100 000 observaciones y 28 variables. Esta información combina medidas biométricas, parámetros fisiológicos, datos administrativos y diagnósticos codificados según la clasificación ICD-9.

Las variables disponibles se dividen en varias categorías:

- **Identificadores y fechas:** ID del paciente, fecha de admisión, fecha de alta. Estas variables, aunque presentes, no son directamente útiles para la predicción de la duración de la estancia

hospitalaria.

- **Comorbilidades codificadas ICD-9:** un conjunto de variables binarias que indican la presencia (1) o la ausencia (0) de ciertas comorbilidades. Esta información es crucial, ya que la literatura muestra que la presencia de comorbilidades impacta directamente en la duración de la estancia [3].
- **Medidas biológicas:** creatinina, nitrógeno ureico en sangre (BUN), hematocrito, sodio, etc. Estas variables continuas informan sobre el estado fisiológico del paciente y pueden influir en la duración de la estancia.
- **Medidas fisiológicas:** IMC (`bmi`), frecuencia respiratoria, pulso. El IMC y la frecuencia respiratoria son variables particularmente pertinentes, mientras que el pulso muestra una variabilidad demasiado amplia para ser un buen predictor.
- **Variables administrativas:** número de readmisiones en los últimos 180 días (`rcount`), género (`gender`), etc.

La variable objetivo es la duración de la estancia hospitalaria (`lengthofstay`, en días).

Esta etapa preliminar permite familiarizarse con la estructura de los datos, identificar los tipos de variables y detectar posibles anomalías (valores faltantes, atípicos o incoherentes).

2.2. Importación y descripción inicial

La importación del conjunto de datos se realizó en Python a través de la biblioteca `pandas` [5]. El conjunto de datos inicial se cargó en un *DataFrame*, y una primera vista permitió verificar la integridad de los datos, los tipos de variables, así como la ausencia de valores faltantes para las columnas esenciales (`lengthofstay`, `bmi`, `creatinine`, etc.).

Esta primera fase descriptiva consistió en examinar:

- Las distribuciones de las variables continuas (media, mediana, rango, cuartiles);
- La distribución de las variables categóricas y discretas;
- La detección de posibles valores atípicos o incoherentes.

No se identificaron valores negativos de LOS, y todas las variables esenciales estaban completas.

2.3. Selección de variables características

Dada la gran dimensión inicial (28 variables), fue necesario seleccionar un subconjunto pertinente para el análisis y el modelado predictivo. La selección de las variables se guio por:

1. El examen de las distribuciones estadísticas y las correlaciones;

2. Las recomendaciones de la literatura científica sobre los factores que influyen en la duración de la estancia hospitalaria [2];
3. La disponibilidad de la información en el conjunto de datos de Kaggle.

Tras el análisis, las variables retenidas son:

Variable	Tipo	Definición
IMC (bmi)	Continua	Índice de masa corporal
Frecuencia respiratoria (respiration)	Continua	Número de respiraciones por minuto
Creatinina (creatinine)	Continua	Nivel medio de creatinina en sangre (mg/dL)
Nitrógeno ureico (bloodureanitro)	Continua	Indicador de función renal (BUN)
Género (gender)	Discreta	Masculino / Femenino
Número de readmisiones (rcount)	Discreta	Número de readmisiones en los últimos 180 días
Comorbilidades ICD-9 (suma) (icd9_comorbidity_sum)	Discreta	Número de comorbilidades principales ICD-9
Diagnósticos secundarios no ICD (secondarydiagnosisnonicd9)	Discreta	Número de diagnósticos secundarios no codificados en ICD-9

Tabla 1: Variables retenidas para el análisis.

Estas variables cubren las principales dimensiones que influyen en la duración de la estancia: características biológicas, fisiológicas, administrativas y comorbilidades médicas.

2.4. Análisis exploratorio y tratamiento de valores faltantes

Una vez seleccionadas las variables, se llevó a cabo un análisis exploratorio detallado para comprender la distribución y las relaciones entre las variables, así como para identificar los valores faltantes o atípicos. Esta etapa incluyó:

- **Estadísticas descriptivas:** media, mediana, cuartiles, varianza y rango para las variables continuas; frecuencias y proporciones para las variables categóricas.
- **Visualizaciones:** histogramas, diagramas de caja, matrices de correlación y diagramas de dispersión para identificar tendencias, relaciones lineales o no lineales y anomalías visuales.
- **Detección de valores atípicos (outliers):** se aplicaron métodos clásicos como el RIC (IQR) y el Z-score para identificar las observaciones extremas. Para algunas variables, se utilizaron métodos basados en la densidad (DBSCAN) para detectar valores raros o inusuales.
- **Gestión de valores faltantes:** aunque la mayoría de las variables esenciales estaban completas, cualquier dato faltante identificado fue analizado para decidir si debía ser imputado (por la mediana para las variables continuas o la moda para las categóricas) o conservado tal cual para no introducir sesgos.

2.5. Transformación y preparación de variables

Con el fin de hacer las variables comparables y adecuadas para los análisis estadísticos y el modelado:

- Las variables continuas fueron estandarizadas (centrado y reducción) cuando fue necesario, en particular para los métodos sensibles a la escala (PCA, clustering).
- Las variables categóricas se codificaron en variables binarias (dummy) o se agruparon si algunas modalidades eran demasiado raras.

- Se crearon variables derivadas, como la suma de comorbilidades ICD-9 (`icd9_comorbidity_sum`) o el número total de diagnósticos secundarios no ICD (`secondarydiagnosisnonicd9`), para sintetizar la información clínica.

3. Análisis exploratorio de datos

El análisis exploratorio constituye una etapa esencial para comprender la estructura de los datos e identificar las características de las variables antes de cualquier modelado predictivo. Permite visualizar las distribuciones, detectar valores extremos y poner en evidencia posibles relaciones entre variables. Nuestro enfoque se articula en tres aspectos: univariado, bivariado y multivariado.

3.0.1. Análisis univariado

El examen univariado de las variables continuas revela información importante sobre la duración de la estancia hospitalaria (`lengthofstay`) y las medidas biológicas y fisiológicas. La media y la mediana del LOS son ambas de 4 días, mientras que la moda es de 1 día, lo que sugiere que la mayoría de los pacientes permanecen poco tiempo, pero que algunas hospitalizaciones prolongadas contribuyen a una larga cola de distribución. La distribución presenta una asimetría positiva moderada (0,63), con una curtosis cercana a cero (-0,03), indicando que la mayoría de los valores se concentran alrededor de la media, pero que existen valores extremos.




Figura 1: Distribución de la duración de la estancia hospitalaria (LOS), mostrando una asimetría positiva.

La variable de readmisión (`rcount`) sigue una distribución fuertemente decreciente: la mayoría de los pacientes tienen solo una admisión, mientras que algunos presentan hasta cinco readmisiones o más, representando casos clínicos complejos que requieren un seguimiento particular. En cuanto al género (`gender`), el ligero predominio femenino (58 %) no tiene un impacto mayor en la interpretación global, pero constituye un factor a considerar para el modelado y el análisis de subgrupos.

Las variables relacionadas con las comorbilidades también muestran distribuciones asimétricas: la suma de las comorbilidades ICD-9 (`icd9_comorbidity_sum`) y el número de diagnósticos secundarios no ICD-9 se concentran en valores bajos, con colas largas para algunos pacientes que presentan una carga clínica elevada. Estos casos extremos pueden influir de manera significativa en la duración de la hospitalización y representan situaciones clínicas particulares a tener en cuenta durante la interpretación estadística.




Figura 2: Distribución del número de diagnósticos secundarios no ICD-9.

Las variables biológicas y fisiológicas presentan comportamientos variados. El IMC (**bmi**) es globalmente simétrico, con una media elevada (29,8), lo que traduce una población mayoritariamente con sobrepeso. La creatinina (**creatinine**) presenta una distribución casi normal, concentrada alrededor del valor central, mientras que el nitrógeno ureico en sangre (**bloodureanitro**) muestra una asimetría muy marcada (17,29) y una curtosis extremadamente alta (528,53), señalando la presencia de valores extremos aislados. La frecuencia respiratoria (**respiration**) es relativamente simétrica pero presenta algunos valores bajos atípicos, que pueden corresponder a casos clínicos particulares o a anomalías de medición.

3.0.2. Análisis bivariado

Para explorar las relaciones entre variables, se realizó un diagrama de pares (pairplot) sobre las variables continuas (IMC, creatinina, nitrógeno ureico y frecuencia respiratoria). Los resultados muestran que, globalmente, no existe una separación clara de los grupos según la duración de la estancia, pero una ligera tendencia sugiere que los pacientes con una frecuencia respiratoria más baja podrían presentar estancias más largas. Esta observación destaca la importancia de los factores clínicos múltiples en la determinación del LOS.

El examen de las variables discretas revela relaciones interesantes: la duración de la estancia aumenta con el número de readmisiones, y la presencia de comorbilidades ICD-9 está correlacionada con el número de diagnósticos secundarios no ICD.




Figura 3: Diagrama de caja de la duración de estancia (LOS) en función del número de readmisiones.

Además, las diferencias de distribución de comorbilidades según el género son significativas, reflejando variaciones biológicas o de atención clínica. Los diagramas de caja confirman que los pacientes con múltiples readmisiones o una carga de comorbilidades elevada tienden a tener hospitalizaciones más largas, ilustrando el efecto combinado de la complejidad médica y el seguimiento de los pacientes sobre la duración de la estancia.

3.0.3. Análisis multivariado

El análisis multivariado se llevó a cabo mediante un análisis de componentes principales (ACP) y agrupamiento (clustering). Los dos primeros componentes principales revelan que la duración de la estancia está influenciada principalmente por la carga de comorbilidades y, en menor medida, por el nitrógeno ureico. El CP1 representa la carga clínica global, mientras que el CP2 corresponde a un eje metabólico o nutricional. La inclusión de cinco componentes permite explicar el 88,3% de la varianza, integrando ejes adicionales relacionados con la respiración, los diagnósticos secundarios y el IMC.




Figura 4: Matriz de cargas (loadings) de los vectores propios del ACP.

El agrupamiento K-means ($k=2$) destaca dos perfiles distintos: los pacientes de estancia corta y aquellos de estancia larga. Los pacientes del clúster de estancia larga presentan una carga clínica más importante y una variabilidad biométrica notable, mientras que el clúster de estancia corta agrupa a la mayoría de los pacientes con condiciones menos complejas. Los clústeres adicionales ($k=3$ o 4) aportan poca información adicional y hacen que la interpretación sea más compleja.

Estos análisis multivariados confirman que la duración de la estancia hospitalaria depende de múltiples factores simultáneos, combinando la carga clínica, las variables biológicas y fisiológicas, así como las características administrativas. También subrayan la existencia de subgrupos de pacientes que presentan perfiles clínicos particulares, cuya atención requiere una consideración específica.

3.1. Detección y análisis de valores atípicos (outliers)

Tras la exploración univariada, bivariada y multivariada, estudiamos la presencia de valores atípicos en el conjunto de datos, con un enfoque particular en las variables **bloodureanitro** (BUN) y **respiration**. Estas variables ya habían mostrado, durante el análisis univariado, valores muy alejados de la media y susceptibles de representar registros extremos o clínicamente significativos.

Para identificar estos outliers, se emplearon varios métodos complementarios: el rango intercuartílico (IQR), el Z-score y el algoritmo de agrupamiento DBSCAN. El método de Grubbs no se utilizó, ya que requiere distribuciones normales y solo es eficaz para detectar un solo outlier a la vez, lo que lo hace inadecuado para un conjunto de datos de gran tamaño y con distribuciones no gaussianas.

La aplicación del IQR sobre la variable BUN permitió detectar un gran número de valores extremos (casi el 20 % de las observaciones), lo que indica que este método captura no solo anomalías potenciales, sino también la variabilidad real de la población hospitalaria. El Z-score, utilizando un umbral de ± 3 , identificó un número más moderado de outliers (1 025 observaciones). El examen de las duraciones de estancia de los pacientes que presentan valores extremos de BUN muestra que estos tienen hospitalizaciones significativamente más largas que los pacientes situados en el rango normal, lo que sugiere que estos valores representan indicadores clínicos pertinentes en lugar de errores de medición.

Para la frecuencia respiratoria, el IQR no era aplicable, ya que la distribución estaba muy concentrada alrededor de un único valor central, haciendo que el rango intercuartílico fuera nulo. El Z-score detectó 2273 outliers, correspondientes a pacientes que presentan frecuencias respiratorias excepcionalmente bajas o altas.




Figura 5: Detección de outliers para la frecuencia respiratoria mediante el método Z-score.

Estos valores extremos se acompañan también de una duración media y mediana de estancia superior a la de otros pacientes, reflejando potencialmente situaciones clínicas graves.

La aplicación del algoritmo DBSCAN en una muestra aleatoria de 5000 pacientes permitió identificar los outliers de manera más precisa y representativa. Para las dos variables estudiadas, DBSCAN detecta menos puntos atípicos que los métodos estadísticos clásicos y aísla claramente las observaciones situadas fuera de las zonas de alta densidad. El examen de las duraciones de estancia asociadas confirma que muchos outliers corresponden a pacientes clínicamente significativos y no a errores o anomalías de entrada.

En conclusión, la alta proporción de valores extremos detectados estadísticamente refleja la heterogeneidad clínica real de la población hospitalaria. Estos outliers no deben ser eliminados, sino considerados

como indicadores de gravedad y evolución del paciente. Constituyen una información esencial para la interpretación de los resultados y el modelado de la duración de la estancia hospitalaria.

3.2. Estrategias de preparación y modelado

Tras el análisis exploratorio, se implementó una fase de ingeniería de Características para adaptar los datos a las hipótesis de los algoritmos de aprendizaje automático:

- **Transformación de variables:** Las distribuciones asimétricas, especialmente para el nitrógeno ureico (**bloodureanitro**) y los diagnósticos secundarios, se normalizaron mediante la transformación de Yeo-Johnson. La frecuencia respiratoria, que presentaba valores extremos clínicamente pertinentes, se trató con un *RobustScaler* (basado en la mediana y el rango intercuartílico) para evitar que estos outliers distorsionaran la varianza de los datos sanos.
- **Discretización del objetivo:** La variable continua **lengthofstay** se convirtió en una variable categórica de tres clases: estancia corta (0-2 días), media (3-7 días) y larga (≥ 8 días). Este enfoque transforma el problema de regresión en un problema de clasificación de riesgo, más pertinente para la ayuda a la decisión operativa.
- **Gestión del desequilibrio:** Ante la subrepresentación crítica de las estancias largas, se estableció un protocolo experimental comparando cuatro estrategias: un modelo base (*Baseline*), ponderación de costos (*Class Weight*), sobremuestreo sintético (*SMOTE*) y submuestreo (*Undersampling*).

3.3. Resultados y análisis

3.3.1. Interpretación de resultados y arbitraje ético

La evaluación comparativa de los modelos resalta una tensión fundamental entre el rendimiento estadístico bruto y la utilidad clínica.

Los resultados muestran que:

- El modelo **Baseline** muestra el mejor puntaje global (Exactitud), pero falla en cumplir su misión principal: solo detecta el 47 % de las estancias largas (Sensibilidad baja). En un contexto hospitalario, esto equivale a no anticipar la necesidad de camas para más de la mitad de los pacientes graves.
- Las estrategias de reequilibrio, en particular la ponderación de clases (**Class Weight**), sacrifican ligeramente la precisión global para elevar drásticamente la tasa de detección de estancias largas a aproximadamente un **84 %**.

Elección final: Desde un punto de vista ético y logístico, el modelo ponderado es superior. Prioriza la sensibilidad (evitar Falsos Negativos) sobre la precisión. Es menos perjudicial para el hospital prevenir una cama por precaución (falsa alarma) que encontrarse saturado por pacientes cuya larga estancia no había sido anticipada.




Figura 6: Matrices de confusión normalizadas comparando las estrategias de gestión del desequilibrio.




Figura 7: Comparación de los puntajes F1-Macro entre las diferentes estrategias.

3.3.2. Limitaciones

A pesar de la riqueza del conjunto de datos, cabe señalar algunas limitaciones:

- Las variables disponibles no cubren todos los factores que pueden influir en el LOS (factores sociales, medicación, intervenciones quirúrgicas específicas).
- Los valores extremos pueden reflejar prácticas clínicas heterogéneas o sesgos de entrada no detectados.
- Los métodos de detección de outliers se basan en umbrales estadísticos, que no siempre distinguen perfectamente entre rareza clínica y anomalía de medición.
- El muestreo para DBSCAN se limitó a 5 000 observaciones, lo que puede reducir la representatividad de los clústeres para el conjunto de 100 000 pacientes.

3.3.3. Síntesis general

El conjunto de los análisis muestra que:

- El LOS está fuertemente influenciado por la carga clínica (comorbilidades, BUN, readmisiones) y las variables fisiológicas (IMC, creatinina, frecuencia respiratoria).
- Los outliers identificados son pertinentes y proporcionan información clínica importante.
- Se pueden distinguir claramente perfiles de pacientes con riesgo de estancias prolongadas mediante métodos multivariados.

Estos resultados proporcionan una base sólida para la construcción de un modelo predictivo robusto.

4. Conclusiones

4.1. Principales contribuciones

Este trabajo ha permitido:

- Preparar y limpiar un conjunto de datos hospitalarios de gran tamaño, listo para el modelado supervisado.
- Identificar las variables más influyentes en la duración de la estancia, combinando información biológica, fisiológica y administrativa.
- Demostrar que los outliers clínicamente significativos no deben ser eliminados, sino integrados en el análisis para enriquecer la predicción.
- Poner en evidencia perfiles de pacientes distintos, útiles para la planificación hospitalaria y la gestión de recursos.
- Establecer una estrategia de modelado ética frente al desequilibrio de clases: la elección de la ponderación (*Class Weight*) permitió duplicar la capacidad de detección de estancias largas en comparación con el modelo estándar, priorizando la seguridad del paciente sobre el rendimiento estadístico bruto.

4.2. Limitaciones y perspectivas

- El análisis sigue siendo descriptivo y exploratorio; el modelado predictivo deberá validarse en datos independientes.
- La información faltante sobre ciertos factores (tratamientos, intervenciones quirúrgicas) puede limitar la precisión de las predicciones.
- Las futuras extensiones podrían incluir técnicas de modelado avanzadas (regresión, bosques aleatorios, modelos de supervivencia) y la integración de datos longitudinales.
- El uso de herramientas de visualización interactiva y tableros de control podría mejorar la comprensión y explotación de los resultados por parte de los equipos clínicos.

4.3. Agradecimientos

Agradezco a la profesora María Bernarda Salazar Sánchez por sus valiosos consejos metodológicos durante el curso "Fundamentos de Ciencia de Datos", así como a la plataforma Kaggle por la disponibilidad del conjunto de datos hospitalarios.

Referencias

- [1] Chou, A. (2021). *Hospital Length of Stay Dataset*. Kaggle. Disponible en: <https://www.kaggle.com/datasets/aayushchou/hospital-length-of-stay> [Consultado el 17 de noviembre de 2025].
- [2] Karim, H., Tara, M., & Etminani, F. (2015). Factors Associated with Length of Hospital Stay: A Systematic Review. *Health Services Research*.
- [3] Rodrigues-Silva, N. (2017). Impact of medical comorbidity in psychiatric inpatient length of stay. *Journal of Mental Health*, 29(6), 1-5.
- [4] NumPy Developers. (2024). *NumPy Documentation*. Disponible en: <https://numpy.org/doc/>
- [5] Pandas Development Team. (2024). *Pandas Documentation*. Disponible en: <https://pandas.pydata.org/docs/>
- [6] Matplotlib Developers. (2024). *Matplotlib Documentation*. Disponible en: <https://matplotlib.org/stable/>
- [7] Scikit-Learn Developers. (2024). *Scikit-Learn User Guide*. Disponible en: <https://scikit-learn.org/stable/>